



ZZN Projekt

8.12. 2024

Ondřej Bahounek (xbahou00) a Peter Pločica (xploci01)

1) Popis dat

Data obsahují demografické informace o zákazníkovi: kategorické jako pohlaví, senioritu, jestli má partnera a jestli jsou finančně závislí. Dále obsahuje informace o tom, jaké služby daný zákazník využívá, jestli využívá telefonní služby, více linek, jestli využívá internetové služby a jaký typ internetu, online zálohu, bezpečnost, technickou podporu a streamovací služby (TV a filmy). Dál obsahuje informace jako typ smlouvy, způsob platby a kvantitativní data o výši platby a délce využívání služeb. V poslední řadě obsahuje "churn", tedy informaci, jestli zákazník od telekomunikační společnosti odešel. Data jsou uložena v jedné velké tabulce v CSV souboru.


2) Úloha - předpověď churn

Pokusíme se u zákazníku předpovídat churn, tedy jestli zákazník ukončí spolupráci s telekomunikační společností. Bude se předpovídat, kteří zákazníci od společnosti s větší pravděpodobností odejdou, abychom mohli odejití zabránit. K tomu se pokusíme zjistit i jaké atributy spolupráce způsobují odejití zákazníka, aby se zjistili důvody odchodu zákazníků.

Řešení


K předpovídání využíváme metody hluboké neuronové sítě a rozhodovacího stromu. Neuronové sítě používáme kvůli jejich vysoké přesnosti, ale bohužel fungují trochu jako black-box, takže nevíme, jak na výsledek přišli. Proto použijeme rozhodovací stromy kvůli jejich dobré interpretovatelnosti výsledků.

Obě metody zvládají na vstupu různé datové typy a nebylo tedy třeba data speciálně připravovat k dolování. Jediný problém byl nepoměr záznamů s patřících do skupiny *churn* "Yes" a *churn* "No". Při předpovídání bez potřebné úpravy se prediktory předpovídali na téměř všechna data *churn* "No", a dosahovali tak velmi dobrých výsledků i bez pochopení dat. To jsme vyřešili nejjednodušším možným způsobem, a to přiřazením větší váhy záznamům, kteří mají *churn* "No". Pomocí *Generate Weight (Stratification)*, které přiřadí váhy třídám, tak aby součet obou tříd přes obě třídy byl stejný.



Nejpřesněji churn okolo 74 % přesnosti předpovídal poměrně plytká neuronová síť s pouze dvěma vrstvami a 50ti neurony v jedné vrstvě. Rozhodovací strom s maximální hloubkou 15 dosahoval podobných výsledků, přesně 74.7 %. To by nebyli špatné výsledky,

ale předpověď *churn* “Yes” měli přesnost kolem 70 %. V úloze bychom spíše chtěli co největší přesnost předpovědí *churn* “Yes” a nevadí nám když kvůli tomu špatně předpovídá pár *churn* “No”. A tak jsme použili *Select Recall* a *Apply Threshold*, abychom posunuli threshold rozhodování tak abychom zachytili více *churn* “Yes” záznamů. Při nastavení thresholdu tak, abychom správně předpověděli alespoň 90 % *churn* “Yes”, celková přesnost neuronové sítě se snížila na 72 % a u stromu, až na 64 % procent.



Deep Learning Model (Deep Learning) ExampleSet (/Local Repository/data/Association Rules)

Result History PerformanceVector (Performance) ExampleSet (Generate Weight (Stratification))


Criterion: accuracy, classification error

Table View Plot View

accuracy: 72.84%

	true No	true Yes	class precision
pred. No	0.083	0.015	84.97%
pred. Yes	0.067	0.135	66.97%
class recall	55.48%	90.20%	

Churn jsme tedy již schopni předvídat s dobrou přesností. Ale důvody odchodu zákazníka nejsou pořád jasné a bohužel u stromů s hloubkou roste i obtížnost rozklíčovat výsledek. Proto jsme také použili strom s maximální hloubkou 5, který dokáže předpovědět skutečné *churn* “Yes” v 97 % případů s celkovou přesností 63 %.



Z výsledků se dá předvídat, že hlavní faktor, jestli někdo odejde od společnosti, je výše měsíčního účtu. U hodnoty pod 99 (asi EUR) je téměř jisté, že zákazník eventuelně odejde. Taktéž je vidět, že zákazníci s dvouletou smlouvou společnost neopouštějí. Uzavírání dlouhodobějších smluv by tedy mělo přispět k retenci zákazníků.

3) Úloha - asociační pravidla


Pokusíme se zjistit, jaké produkty zákazníci nakupují společně s jakými jinými produkty, abychom mohli zákazníkům cíleně doporučovat produkty, které by mohli chtít podle toho, co si pořizují ostatní klienti.

Řešení


Pro získání kombinací produktů použijeme algoritmus na zjištění frekventovaných množin, konkrétně algoritmus využívající FP-stromu. Následně z frekventovaných množin vytvoříme asociační pravidla.

Pro dolování frekventovaných množin jsou zapotřebí data ve formátu, kde každý atribut nabývá pouze pravdivostních hodnot. Bylo tedy zapotřebí upravit data tak, aby byla použitelná k dolování. V první řadě jsme z dat odstranili nepotřebné atributy. Jednalo se o takové atributy, které neobsahují produkty, ale údaje jako churn, délka smlouvy, výše měsíční částky atd. Data u produktu *Multiple Lines* může nabývat tří hodnot: "Yes", "No", "No phone service". "No phone service" znamená, že zákazník si ani nemůže pořídit *Multiple Lines*, protože nemá produkt *Phone Service*, který je potřebný pro *Multiple Lines*. Museli jsme teda hodnotu "No phone service" vyměnit za obyčejné "No". Obdobně atributy internetových služeb nabývají hodnot "No Internet Service", což jsme vyřešili stejným

způsobem. Následně nominální hodnoty musíme převést na binominální tak, že pokud atribut nabývá třeba 3 hodnot, tak ho převedeme na tři atributy, které nabývají binárního Yes/No. A na konec jsme museli upravit atribut *Gender*, který nabývat binomiálních hodnot *Male/Female*. Ručně jsme ho museli předělat na atributy *Male* a *Female*.



Následně dolování se provedlo pomocí operátorů *FP-Growth* a *Create Ascoration Rules*. Jako minimální podporu pro frekventované množiny, jsme nastavili 0.7. Pro asociační pravidla jsme minimální hodnotu důvěry nastavili také na 0.7.



Největší frekventované množiny dosáhli kardinality 3. Z nichž se vytvořilo necelých dvacet asociačních pravidel s důvěrou 70 %, kde se se nejčastěji ukazují očekávané kombinace jako Streaming Movies a Streaming TV, ale aji zajímavější pravidla třeba jako Multiple Lines & Streaming TV => Fiber Optic Internet. Podle těchto pravidel můžeme cíleně mířit nabídky na zákazníky, aby byla co největší šance, že si od nás přikoupí další služby.

No.	Premises	Conclusion	Support	Confidence
4	StreamingTV	StreamingMovies	0.275	0.717
5	Partner, StreamingMovies	StreamingTV	0.161	0.746
6	Partner, StreamingTV	StreamingMovies	0.161	0.746
7	InternetService = Fiber optic, StreamingMovies	StreamingTV	0.186	0.748
8	InternetService = Fiber optic, StreamingTV	StreamingMovies	0.186	0.749
9	StreamingTV, OnlineBackup	StreamingMovies	0.148	0.750
10	StreamingMovies, OnlineBackup	StreamingTV	0.148	0.752
11	MultipleLines, StreamingMovies	StreamingTV	0.172	0.760
12	MultipleLines, StreamingTV	StreamingMovies	0.172	0.767
13	MultipleLines, StreamingMovies	InternetService = Fiber optic	0.174	0.772
14	MultipleLines, StreamingTV	InternetService = Fiber optic	0.174	0.777
15	StreamingMovies, DeviceProtection	StreamingTV	0.178	0.786
16	StreamingTV, DeviceProtection	StreamingMovies	0.178	0.800
17	Dependents	Partner	0.248	0.829

4) Úloha - shlukování podle smlouvy a plateb

Zadáním je rozdělit zákazníky podle toho, jak dlouho využívají služby dané společnosti a jejich měsíční a roční útraty. Na základě tohoto rozdělení pak může společnost podnikat kroky pro udržení svých zákazníků.


Řešení

Na vytvoření shluků využijeme metodu K-means kvůli její rychlosti a kvůli dobré a srozumitelné interpretaci výsledků. Počet shluků nastavíme 3.

Na řešení této úlohy nebyly zapotřebí všechny atributy a pomocí *Select Attributes* jsme všechny nepotřebné atributy odstranili. Ponechány byli *Contract*, *MonthlyCharges*, *TotalCharges* a *tenure*.

Metoda K-means vyžaduje, aby všechny atributy byly numerické. Proto bylo nutné převést atribut *Contract* z nominálního kategorického na numerický, k čemu jsme využili *Nominal to Numerical* a následně změnily typ pomocí *Guess Type*.

Po této transformaci jsme použili *Replace Missing Values* pro případ, že by v datové sadě někde chyběla hodnota.



Cluster Model

Cluster 0: 1624 items

Cluster 1: 1260 items

Cluster 2: 4159 items

Total number of items: 7043

Attribute	cluster_0	cluster_1	cluster_2
Contract = Month-to-month	0.480	0.183	0.689
Contract = One year	0.300	0.302	0.145
Contract = Two year	0.220	0.516	0.165
tenure	43.789	64.364	18.220
MonthlyCharges	77.441	97.918	49.766
TotalCharges	3264.175	6291.771	685.894

Výsledkem shlukování jsou 3 shluky, z kterých je shluk 2 nejpočetnější. Tento shluk obsahuje zejména krátkodobé zákazníky s měsíčními účty, které jsou ze všech shluků nejnižší. Zákazníci z této skupiny jsou náchylní k odchodu. Z tohoto důvodu by měla společnost podnikat kroky, aby zvýšili retenci zákazníků, například aby zákazníci přešli k dlouhodobým smlouvám pomocí akciových personalizovaných balíčků.

Shluk 0 představuje zákazníky s vyváženými poplatky a střední dobou používání služeb. Pro tuto skupinu zákazníků může se společnost usilovat o to, aby zákazníci přešli na dlouhodobé smlouvy (většina zákazníků má měsíční), například pomocí zvýhodněných nabídek služeb.

V shluku 1 jsou nejvěrnější a nejziskovější zákazníci, tedy zákazníci s dlouhodobými smlouvami (zejména dvouletými) a nejvyššími měsíčními účty. Tuto skupinu zákazníků potřebuje společnost udržet spokojenou, například pomocí různých odměn.